

MapReduce Desarrollo en Java y en Python

Prof. Waldo Hasperué whasperue@lidi.info.unlp.edu.ar

#### **Temario**

- MapReduce
  - Combiner
  - Jobs
  - Pasaje de información

#### **MAPREDUCE**

Java

- Función combiner
- Ejecución de varios jobs
- Pasaje de información a los TaskTrackers
- Lectura de archivos en el HDFS
- Tipos de datos personalizados

```
public class WCCombiner extends Reducer<Text, LongWritable, Text, LongWritable>
  public void reduce(Text key, Iterable<LongWritable> values, Context context)
                                         throws IOException, InterruptedException {
         int times = 0;
         for (@SuppressWarnings("unused") Object val: values) {
            times++:
         context.write(key, new LongWritable(times));
```

```
public class WCCombiner exter ds Reducer<Text, LongWritable, Text, LongWritable>
   public void reduce(Text key, Iterable<LongWritable> values, Context context)
                                         throws IOException, InterruptedException {
         int times = 0:
         for (@SuppressWarnings("unused") Object val: values) {
            times++:
         context.write(key, new LongWritable(times));
```

En Java la función combiner se implementa como subclase de Reducer

```
public class Worker extends Configured implements Tool {
  private Job setupJob() throws IOException{
         Configuration conf = getConf();
         Job job = new Job(conf, "WordCount");
         job.setJarByClass(Worker.class);
         //configure Mapper
         //configure combiner
         job.setCombinerClass(WCCombiner.class);
         //configure Reducer
```

public class Worker extends Configured implements Tool {

```
private Job setupJob() throws IOException{
    Configuration conf = getConf();
    Job job = new Job(conf, "WordCount");
    job.setJarByClass(Worker.class);

//configure Mapper
...
```

En la mayoría de los problemas, como función combiner, se usa la misma implementación que el reducer

```
//configure combiner
job.setCombinerClass(WCReducer.class);
```

//configure Reducer

. . .

El mapper solo escribe el valor con una clave única: para que el mismo reduce reciba todos los valores

```
public class MaxReducer extends Reducer<Text, DoubleWritable,
                                                       Text, DoubleWritable >
         public void reduce(Text key, Iterable<DoubleWritable> values,
                                                          Context context) {
                  double maximo = -99999:
                  for (DoubleWritable val : values) {
                            double double_value = val.get();
                            if(double_value > maximo)
                                      maximo = double value;
         context.write(new Text("Maximo"), new DoubleWritable(maximo));
```

El reducer recibe todos los valores y devuelve el máximo de ellos

```
context.write(new Text("Maximo"), new DoubleWritable(maximo));
```

```
public class Worker extends Configured implements Tool {
    private Job setupJob() throws IOException{
        ...

        job.setMapperClass(MaxMapper.class);
        job.setReducerClass(MaxReducer.class);
        job.setCombinerClass(MaxReducer.class);
        ...
}
```

En este ejemplo, el combiner es exactamente el mismo que el reducer

```
public class Worker extends Configured implements Tool {
         public int run(String[] args) throws Exception {
            Job job; boolean success;
            job = setupSucProdJob(args);
            success = job.waitForCompletion(true);
            if (!success){
                    System.out.println("Error SucProd job"); return -1;
            job = setupSucJob(args);
            success = job.waitForCompletion(true);
            if (!success){
                    System.out.println("Error Suc job"); return -1;
            return 0;
         }}
```

```
public class Worker extends Configured implements Tool {
          public int run(String[] args) throws Exception {
            Job job; boolean success;
            job = setupSucProdJob(args);
            |success = job.waitForCompletion(true);
            if (!success){
                    System.out.println("Error SucProd job"); return -1;
            job = setupSucJob(args);
            success = job.waitForCompletion(true);
            if (!success){
                                             Suc job");
                    System.out.println(
                                                           return -1;
            return 0;
         }}
```

El segundo job se ejecutará una vez que finalice el primero

```
public class Worker extends Configured implements Tool {
           private Job setupSucProdJob(String[] args) throws IOException{
           String inputDir = args[0]; , outputDir = "intermediateDir";
           if(fs.exists(new Path(outputDir)
                                                fs.delete(new Path(outputDir),true); }
           FileInputFormat.addInputPath(job, new Path(inputDir));
           FileOutputFormat.setOutputPath(job, new Path(outputDir));
           return job;
           private Job setupSucJob(String[] args) throws IOException{
           String inputDir = "intermediateDir", outputDir = "; args[1];
           if(fs.exists(new Path(outputDir))){    fs.delete(new Path(outputDir),true);    }
           FileInputFormat.addInputPath(job, new Path(inputDir));
           FileOutputFormat.setOutputPath(job, new Path(outputDir));
           return job;
```

```
public class Worker extends Configured implements Tool {
           private Job setupSucProdJob(String[] args) throws IOException{
           String inputDir = args[0]; , outputDir = "intermediateDir";
           if(fs.exists(new Path(outputDir)
                                                fs.delete(new Path(outputDir),true); }
           FileInputFormat.addInputPath(jol
                                               new Path(inputDir));
           FileOutputFormat.setOutputPath(
                                                 new Path(outputDir));
           return job;
           private Job setupSucJob(String[] a
                                                     rows IOException{
           String inputDir = "intermediateDir",
                                                         = "; args[1];
           if(fs.exists(new Path(outputDir))){
                                                         (new Path(outputDir),true); }
           FileInputFormat.addInputPath(job, r
                                                           putDir));
           FileOutputFormat.setOutputPath(job
                                                            putputDir));
           return job;
```

El primer job lee el directorio de entrada y escribe la salida en un directorio temporal intermedio

```
public class Worker extends Configured implements Tool {
           private Job setupSucProdJob(String[] args) throws IOException{
           String inputDir = args[0]; , outputDir = "intermediateDir";
           if(fs.exists(new Path(outputDir)
                                               fs.delete(new Path(outputDir),true); }
           FileInputFormat.addInputPath(job, new Path(inputDir));
           FileOutputFormat.setOutputPath(job, new Path(outputDir));
           return job;
           private Job setupSucJob(String[] args) throws IOException{
           String inputDir = "intermediateDir", outputDir = "; args[1];
           if(fs.exists(new Path(output(1))){
                                                fs.delete(new Path(outputDir),true); }
           FileInputFormat.addInputPath
                                              new Path(inputDir));
                                                  www.Path(outputDir));
           FileOutputFormat.setOutputPat
           return job;
```

El segundo job lee el directorio intermedio y escribe la salida en el directorio de salida especificado

```
public class Worker extends Configured implements Tool {
        public int run(String[] args) throws Exception {
          Job job; boolean success, continuar = true;
          job = setupIterableJob(args);
          while (continuar){
                    success = job.waitForCompletion(true);
                    if (!success){
                          System.out.println("Error job"); return -1;
                    continuar = evaluarCondicionFin();
          return 0;
```

return 0;

public class Worker extends Configured implements Tool { public int run(String[] ard Esta evaluación involucra leer en Job job; boolean suc HDFS la salida parcial del MapReduce para saber si hay que continuar o no con el Job job = setupIterableJol while (continuar){ success = job.waitf (etion(true); if (!success){ System.out.p ("Error job"); return -1; continuar = evaluarCondicionFin();

```
public class Worker extends Configured implements Tool {
         public int run(String[] args) throws Exception {
           Job job; boolean success, continuar = true;
           job = setupIterableJob(args); int ite = 0;
           while (continuar){
                   conf.setInt("ite", ++ite);
                      success = waitForCompletion(true);
                      if (!success){
                              System.ou
                                               "Error job"); return -1;
                      continuar = eval
                                         Mediante el objeto Configuration
                                           podemos pasarle datos a los
           return 0:
                                              mapper y los reducers.
                                            Recibe un "label" y un valor
                                                      asociado
```

Luego podemos usar la variable iteración en cada una de la llamadas a la función map.

Si el contexto no tiene el label "ite" devuelve el valor por defecto pasado como argumento.

# Leyendo archivos en el FSD

Para leer un archivo alojado en el FSD

```
FileSystem fs = FileSystem.get(new
                      URI("hdfs://localhost:54310"), conf);
FSDataInputStream fin = fs.open(new
                      Path("DirSalida\part-r-00000"));
String line = fin.readLine();
while(line != null){
       System.out.println(line);
       line = fin.readLine();
fin.close();
```

- Muchas veces como clave o como valor necesitamos tuplas de datos.
  - Ejemplo del producto más vendido por sucursal.
    - <(suc\_prod), cant> , <suc, (prod\_max)>
- Todo el tiempo hay que hacer concatenación y splits de strings.
- Es más "elegante" usar tipos writable personalizados.

```
import java.io.DataInput;
import java.io.DataOutput;
import java.io.IOException;
import org.apache.hadoop.io.Writable;
import org.apache.hadoop.io.WritableUtils;
public class SucProdWritable implements Writable {
  String sucursal, producto;
  public SucProdWritable () {}
  public SucProdWritable (String s, String p) {
     this.sucursal = s;
     this.producto = p;
```

. . .

```
public void readFields(DataInput in) throws IOException {
     sucursal = WritableUtils.readString(in);
     producto = WritableUtils.readString(in);
public void write(DataOutput out) throws IOException {
     WritableUtils.writeString(out, sucursal);
     WritableUtils.writeString(out, producto);
```

@Override public String toString() { return this.sucursal+ "\t" + this.producto; public String getSucursal() { return sucursal; public String getProducto() { return producto;

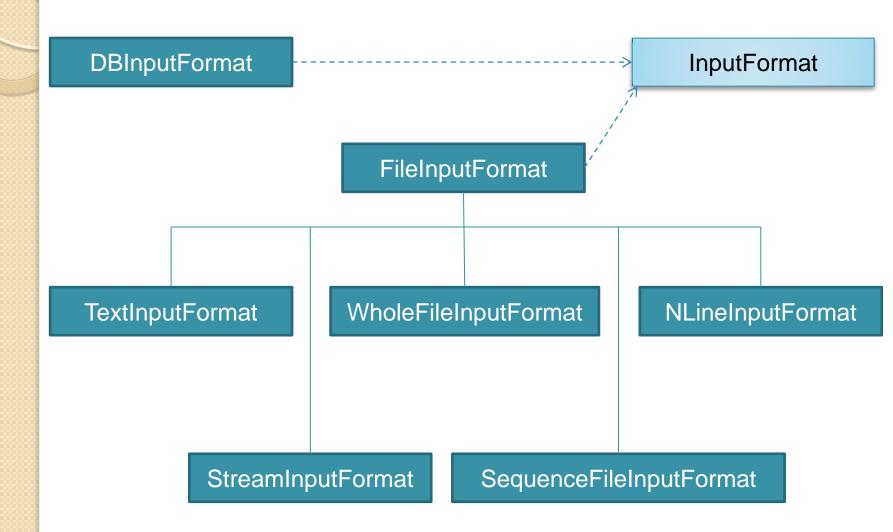
- Todos los archivos se dividen en splits. Un split es lo que procesa un mismo proceso mapper.
- Cada split se divide en registros. Un registro es lo que procesa una invocación a la función map.
- Por lo general un split es de 64MB
- Hasta ahora vimos que un registro es una línea de texto.

- InputSplit es la interface que representa los split y tiene la longitud y la locación de un split.
- Es una referencia a los datos.

```
public interface InputSplit extends Writable {
    long getLength();
    String[] getLocations();
}
```

 InputFormat es la interface encargada de realizar los splits y dividirla en registros.

- Hadoop puede procesar varios tipos de entrada
  - Archivos de texto
    - XML
  - Archivos binarios
    - Imágenes, videos, audios
  - Bases de datos



#### **MAPREDUCE**

#### Python

- Función combiner
- Ejecución de varios jobs
- Pasaje de información a los TaskTrackers
- Lectura de archivos en el HDFS

#### Función combiner

 En python la función combiner es un archivo con extensión .py el cual se debe pasar como argumento al comando hadoop.

hadoop jar hadoop-streaming-2.6.0.jar

- -input entrada
- -output salida
- -mapper /mapper.py
- -reducer /reducer.py
- -combiner /combiner.py

#### Función combiner

 En python la función combiner es un archivo con extensión .py el cual se debe pasar como argumento al comando hadoop.

hadoop jar hado

El archivo para la función combiner podría ser el mismo archivo que para la etapa de reduce, si corresponde.

- -input entraga
- -output salida
- -mapper /mapper/y
- -reducer /reducer.py
- -combiner /combiner.py

 En python el proceso driver es un script bash o un programa en python. La ejecución de más de un job se realiza con la llamada a más de un comando hadoop.

```
#!/bin/bash
hadoop jar hadoop-streaming-2.6.0.jar
-input entrada -output temporal
-mapper /map1.py -reducer /red1.py
hadoop jar hadoop-streaming-2.6.0.jar
-input temporal -output salida
-mapper /map2.py -reducer /red2.py
```

• En python el proceso driver es un script bash a un programa en python. La ejecución de la con la llamada a entrada en el segundo job

```
#!/bin/bash
hadoop jar hadoop jar hadoop-streaming-2.6.0.jar
-mappe /map1.py -reducer /red1.py
hadoop jar hadoop-streaming-2.6.0.jar
-input temporal -output salida
-mapper /map2.py -reducer /red2.py
```

 Hay un proyecto que intenta resolver la ejecución de varios jobs en un único llamado del comando hadoop.

https://github.com/hyonaldo/hadoop-multiple-streaming

 Existe otro proyecto que permite la ejecución de varios jobs escribiendo solo código python.

https://pythonhosted.org/mrjob/

 El mismo script bash que actúa como driver se utiliza para la paremetrización de los jobs.

hadoop jar hadoop-streaming-2.6.0.jar

- -input entrada
- -output salida
- -mapper/mapper.py arg1 arg2
- -reducer/reducer.py arg3 arg4

 Los argumentos enviados por línea de comando son recibidos en el script de python.

#### mapper.py

```
import sys
arg1 = sys.argv[1]
arg2 = sys.argv[2]
```

## Leyendo archivos en el DFS

 Para leer archivos que están en el DFS desde python, primero hay que copiarlo al FS local, ejecutando el comando hdfs.

#### driver.py

```
import os
while(true):
    os.system("hadoop ...")
    os.system("hdfs dfs -copyToLocal ...")
    f = open ("filename", "r")
    datos = f.readlines()
    f.close()
```